

Matematički fakultet, Univerzitet u Beogradu

Seminarski rad iz predmeta: Istraživanje podataka 2

Klasifikacija gramatičkih facijalnih ekspresija

Poređenje algoritama klasifikacije na 3D facial landmarks podacima

Autor: Zarija Trtović

Broj indeksa: 39/2020

Profesor: Mirjana Maljković Ružičić

April 2026.

Sadržaj

1	Tekst zadatka	3
2	Opis podataka	3
2.1	Izvor i struktura	3
2.2	Osnovna statistika	4
2.3	Vizualizacija	4
3	Opis obrade podataka	5
3.1	Učitavanje i spajanje	5
3.2	Preprocesiranje (čišćenje)	5
3.3	Ciljni atributi	5
3.4	Train/test split i skaliranje	6
4	Redukcija atributa i eksperimenti sa parametrima	6
4.1	PCA eksperiment	6
4.2	SelectKBest eksperiment	7
4.3	KNN eksperiment – izbor k	7
4.4	Decision Tree eksperiment – max_depth	8
4.5	MLP eksperiment – arhitektura i aktivacija	8
4.6	SVM eksperiment – kernel	9
5	Metod – algoritmi i evaluacija	9
5.1	Korišćeni algoritmi	9
5.2	Dizajn eksperimenta	10
5.3	Metrike	10
6	Rezultati i tumačenje	10
6.1	Top modeli	10
6.2	Poređenje algoritama (prosek po svim kombinacijama)	11
6.3	Poređenje feature skupova (prosek po svim modelima)	11
6.4	Najbolji model – MLP sa PCA(75), cilj Expression	12
6.5	Per-class analiza i uticaj veličine klase	13
6.6	Confusion matrice za sve modele (Expression, All_Features)	15
6.7	Label cilj – binarna klasifikacija aktivna/neaktivna	15
7	Dodatne analize	16
7.1	GridSearchCV tuning	16
7.2	Stratified k-fold krosvalidacija (5-fold)	17
7.3	Čuvanje modela	17
8	Zaključak	17

1 Tekst zadatka

Zadatak seminarskog rada je klasifikacija **gramatičkih facijalnih ekspresija** iz istoimenog skupa podataka sa UCI repozitorijuma. Potrebno je:

- izvršiti preprocesiranje podataka,
- primeniti **minimum 5 algoritama klasifikacije**,
- napraviti modele sa **svim atributima** i sa **različitim redukovanim skupovima atributa** i uporediti ih,
- u skupu u kom ima smisla koristiti **različite ciljne attribute** i napraviti modele za svaki od njih,
- vizuelno prikazati podatke (2D/3D),
- izvršiti analizu rezultata i uporediti dobijena rešenja.

Rad je realizovan u Python-u uz biblioteku `scikit-learn`. Sav kod se nalazi u notebook-u `notebooks/facial_expressions.ipynb`, a svi rezultati, figure i sačuvani modeli se automatski generišu pri izvršavanju.

2 Opis podataka

2.1 Izvor i struktura

Skup podataka *Grammatical Facial Expressions* potiče sa UCI Machine Learning Repository. Podaci su dobijeni sa *Microsoft Kinect* senzora i sadrže **3D koordinate 100 tačaka lica** (facial landmarks) tokom izvođenja gramatičkih facijalnih ekspresija u brazilskom znakovnom jeziku (LIBRAS).

- **18 *datapoints* fajlova**: svaki red = jedan frame, 301 kolona (timestamp + 100×3 koordinate).
- **18 *targets* fajlova**: binarne oznake (0 = neaktivna, 1 = aktivna) za svaki frame.
- Imenovanje fajlova: `[korisnik]_[ekspresija]_datapoints.txt`.
- Korisnici: **A** i **B** (dva subjekta).
- Ekspresije (9): *affirmative, conditional, doubt_question, emphasis, negative, relative, topics, wh_question, yn_question*.


2.2 Osnovna statistika

Metrika	Vrednost
Ukupno frame-ova	27 936
Broj atributa (feature-a)	300
Broj korisnika	2 (A: 13 610, B: 14 326)
Broj tipova ekspresija	9
Distribucija labela (0/1)	18 059 / 9 877
Procenat aktivnih (label=1)	35,36 %
Nedostajućih vrednosti	0


Tabela 1: Osnovna statistika dataseta pre preprocesiranja.

2.3 Vizualizacija

Distribucija klasa i primer 3D rekonstrukcije jednog frame-a prikazani su na slikama 1 i 2.



Slika 1: Broj frame-ova po ekspresijama (levo) i odnos aktivnih/neaktivnih frame-ova (desno).



Slika 2: 3D prikaz 100 facial landmarks za jedan frame, grupisanih po delovima lica (oči, obrve, nos, usta, kontura).

3 Opis obrade podataka

3.1 Učitavanje i spajanje

Funkcija `load_all_data` parsira svih 18 *datapoints* i 18 *targets* fajlova, dodaje kolone `user` i `expression` iz imena fajla i spaja sve u jedan `DataFrame` oblika **(27 936, 304)**.

3.2 Preprocesiranje (čišćenje)

1. **Uklanjanje timestamp kolone** – kolona `0.0` (vreme snimanja) ne nosi informaciju relevantnu za klasifikaciju.
2. **Tretiranje $Z=0$ vrednosti** – Kinect ne uspeva uvek da izmeri dubinu, pa unosi vrednost 0. Ove vrednosti su zamenjene **medijanom te Z-koordinate**. Posle zamene: 0 $Z=0$ vrednosti, 0 NaN.
3. **Čuvanje verzija dataseta** – `dataset_original.csv` i `dataset_preprocessed.csv`.

3.3 Ciljni atributi

Korišćena su **dva ciljna atributa** (u skladu sa zahtevom zadatka):

- **Cilj A – expression (9 klasa):** tip gramatičke ekspresije. Label encoding (`affirmative`→0, `conditional`→1, ..., `yn_question`→8).
- **Cilj B – label (2 klase):** da li je u datom frame-u ekspresija aktivna (1) ili neaktivna (0).

3.4 Train/test split i skaliranje

- **Train/test split:** 80 % / 20 %, `stratify` po ciljnom atributu, `random_state=42`. Train: 22 348 uzoraka, Test: 5 588 uzoraka.
- **StandardScaler:** fit *samo na train* setu, transform zatim primenjen na test set (sprečava data leakage). Skaliranje je neophodno jer su X,Y u pikselima (~200–400) a Z u milimetrima (~800–1600).
- Kreirani su **odvojeni scaler-i** za cilj A i cilj B.

4 Redukcija atributa i eksperimenti sa parametrima


Napravljena su **tri skupa atributa** koja se koriste u svim daljim modelima:

1. **All_Features:** svih 300 originalnih atributa.
2. **PCA:** broj komponenti odabran eksperimentalno.
3. **SelectKBest:** k odabrano eksperimentalno (ANOVA F-test, `f_classif`).

Za svaku od ovih tehnika, kao i za algoritme KNN, Decision Tree, MLP i SVM, urađen je poseban **eksperiment za biranje hiperparametara**.

4.1 PCA eksperiment

Testiran broj komponenti: {10, 20, 30, 50, 75, 100, 150, 200}. Kao probne modele koristili smo KNN, MLP i SVM na **expression** cilju.




Slika 3: Accuracy vs. broj PCA komponenti (levo) i kumulativna objašnjena varijansa (desno).

Rezultat: optimalno **PCA(75)** sa MLP dostiže **Accuracy = 0,9714** i objašnjava **99,78 %** varijanse. Daljim povećanjem broja komponenti (100, 150, 200) skor stagnira ili opada – 75 komponenti je dobar trade-off između kompresije i informacije. Ovo se koristi kao PCA skup u daljem radu.

4.2 SelectKBest eksperiment

Testiran $k \in \{50, 100, 150\}$.




Slika 4: Accuracy u zavisnosti od broja odabranih feature-a (SelectKBest).

Rezultat: biramo **k=100** (MLP Acc=0,9422). Iako k=150 daje neznatno bolji skor (MLP Acc=0,9563), 100 feature-a daje vrlo slične rezultate uz 50 manje feature-a – bolji trade-off između performansi i kompleksnosti modela. Top-10 feature-a sa najvećim F-skorom su X-koordinate tačaka oko usta (41x, 42x, 52x, 97x, 51x, 98x, 40x, 62x, 50x, 39x), što je intuitivno jer pokret usta nosi ključne informacije za gramatičke ekspresije.

4.3 KNN eksperiment – izbor k

Testiran $k \in \{1, 3, 5, 7, 11, 15, 21\}$.




Slika 5: Accuracy i F1 KNN-a u funkciji broja suseda.

Rezultat: $k = 1$ daje najviši skor ($\text{Acc}=0,9599$), ali je podložan šumu. U finalnom treningu koristimo $k=5$ ($\text{Acc}=0,9406$) kao robusniji izbor. Dalje povećanje k monotono pogoršava performansu ($k=21$: $\text{Acc}=0,8975$), pošto previše dalekih suseda razvodnjava signal.

4.4 Decision Tree eksperiment – max_depth

Testirana dubina $\in \{3, 5, 7, 10, 15, 20\}$.




Slika 6: Accuracy i F1 Decision Tree-a u funkciji max_depth.

Rezultat: accuracy snažno raste sa dubinom: $\text{max_depth}=3$ daje samo 0,3176, $\text{max_depth}=15$ dostiže 0,8960, a $\text{max_depth}=20$ vrh od 0,9069. Za finalni model koristimo **max_depth=15** kao kompromis između performanse i rizika od overfitting-a.

4.5 MLP eksperiment – arhitektura i aktivacija

Testirane arhitekture: (50), (100), (100,50), (100,100), (150,100), (200,100,50); aktivacije: relu, tanh.




Slika 7: MLP Accuracy i F1 po arhitekturi i aktivacionoj funkciji.

Rezultat: najbolji skor postiže **(200, 100, 50)** arhitektura – relu daje $\text{Acc}=0,9792$, a tanh $\text{Acc}=0,9730$. Performansa uglavnom raste sa kapacitetom mreže, bez znakova overfitting-a. U glavnom eksperimentu koristi se **(200, 100, 50) + tanh**: iako je u ovom eksperimentu (na svih 300 atributa) relu neznatno bolji, u kombinaciji sa PCA(75) tanh se pokazao kao stabilniji izbor i daje najbolji ukupan rezultat ($\text{Acc}=0,9817$, vidi tabelu 3).

4.6 SVM eksperiment – kernel

Testirani kerneli: linear, rbf, poly, sigmoid.



Slika 8: SVM Accuracy i F1 po kernel funkciji.

Rezultat: rbf kernel je najbolji ($\text{Acc}=0,9053$), linear (0,8443) i poly (0,8305) značajno zaostaju, a sigmoid se pokazao kao neupotrebljiv ($\text{Acc}=0,2069$). Ovo potvrđuje da je granica između klasa *nelinearna*.

5 Metod – algoritmi i evaluacija

5.1 Korišćeni algoritmi

Primenjeno je **5 algoritama** pokrivajući različite paradigme mašinskog učenja:

Algoritam	Hiperparametri
Logistic Regression	max_iter=3000, random_state=42
K-Nearest Neighbors	n_neighbors=5
Decision Tree	max_depth=15, random_state=42
Support Vector Machine	kernel='rbf', C=1.0, random_state=42
Neural Network (MLP)	hidden_layer_sizes=(200, 100, 50), activation='tanh', max_iter=500

Tabela 2: Finalne konfiguracije modela korišćene u glavnom eksperimentu.

5.2 Dizajn eksperimenta

Svaki od 5 algoritama je treniran na **3 skupa atributa** (All_Features, PCA_75, KBest_100) i **2 ciljna atributa** (Expression, Label) – ukupno $5 \times 3 \times 2 = 30$ modela.

5.3 Metrike

Korišćene su standardne metrike: **Accuracy, Precision, Recall, F1-Score**. Za multi-klasni slučaj (Expression, 9 klasa) koristi se **weighted average**, za binarni (Label) podrazumevana binarna definicija.

6 Rezultati i tumačenje

6.1 Top modeli

Model	Features	Target	Acc	Prec	Rec	F1
Neural Network (MLP)	PCA_75	Expression	0,9817	0,9818	0,9817	0,9817
Neural Network (MLP)	All_Features	Expression	0,9730	0,9731	0,9730	0,9730
Neural Network (MLP)	KBest_100	Expression	0,9594	0,9599	0,9594	0,9595
K-Nearest Neighbors	PCA_75	Expression	0,9418	0,9422	0,9418	0,9418
K-Nearest Neighbors	All_Features	Expression	0,9406	0,9410	0,9406	0,9405
Neural Network (MLP)	All_Features	Label	0,9401	0,9399	0,8871	0,9128
Neural Network (MLP)	PCA_75	Label	0,9368	0,9220	0,8973	0,9095
Neural Network (MLP)	KBest_100	Label	0,9345	0,9099	0,9044	0,9071
K-Nearest Neighbors	KBest_100	Label	0,9139	0,9082	0,8416	0,8737
K-Nearest Neighbors	All_Features	Label	0,9091	0,9064	0,8284	0,8657

Tabela 3: Top 10 modela sortiranih po Accuracy.

6.2 Poređenje algoritama (prosek po svim kombinacijama)


Algoritam	Accuracy	Precision	Recall	F1
Neural Network (MLP)	0,9542	0,9478	0,9338	0,9406
K-Nearest Neighbors	0,9194	0,9176	0,8807	0,8982
Support Vector Machine	0,8670	0,8727	0,8044	0,8355
Decision Tree	0,8631	0,8547	0,8155	0,8339
Logistic Regression	0,7693	0,7622	0,6821	0,7167

Tabela 4: Prosečne performanse po algoritmu (6 kombinacija po algoritmu).

6.3 Poređenje feature skupova (prosek po svim modelima)

Skup atributa	Accuracy	Precision	Recall	F1
All_Features (300)	0,8964	0,8937	0,8486	0,8697
PCA_75	0,8792	0,8746	0,8249	0,8476
KBest_100	0,8482	0,8447	0,7964	0,8177

Tabela 5: Prosečne performanse po feature setu (10 modela po setu).




Slika 9: Poređenje modela: prosek po algoritmu (gore levo), prosek po feature setu (gore desno) i heatmap po kombinaciji za Expression i Label cilj.

6.4 Najbolji model – MLP sa PCA(75), cilj Expression

Accuracy = 0,9817 F1 = 0,9817

Klasa	Precision	Recall	F1	Support
affirmative	0,98	0,98	0,98	427
conditional	0,98	0,98	0,98	788
doubt_question	0,99	0,99	0,99	562
emphasis	0,98	0,98	0,98	550
negative	0,98	0,98	0,98	541
relative	0,98	0,98	0,98	847
topics	0,97	0,98	0,98	724
wh_question	0,99	1,00	0,99	523
yn_question	0,99	0,97	0,98	626
Weighted avg	0,98	0,98	0,98	5588


Tabela 6: Classification report najboljeg modela (MLP + PCA_75, Expression).



Slika 10: Matrica konfuzije najboljeg modela. Dominira dijagonala; preostale (sitne) greške su ravnomerno raspoređene – nijedna klasa nije sistematski mešana sa drugom.

6.5 Per-class analiza i uticaj veličine klase

Per-class analiza svih 5 algoritama (Expression, All_Features) prikazana je na slici 11.




Slika 11: Heatmap-i Precision, Recall i F1 po klasama i modelima (Expression, All_Features).

Glavni nalazi:

- Sve klase imaju **F1 $\geq$ 0,92** za MLP i KNN.


- **Logistic Regression** je jedini algoritam sa kombinacijama $F1 < 0,80$ – za 6 od 9 klasa (npr. *affirmative* $F1=0,66$, *topics* $F1=0,73$), što potvrđuje da problem nije linearno separabilan.
- *wh_question* se najlakše prepoznaje ($F1 \approx 0,99$ kod MLP) jer ima karakteristične pokrete obrva.

Uticaj veličine klase. Korelacija između broja uzoraka klase i njenog F1 skora kod MLP-a je **-0,087** – praktično nulta. Najmanja klasa (*affirmative*, 2 136 uzoraka) ima $F1=0,96$, najveća (*relative*, 4 234 uzoraka) ima $F1=0,97$. *Veličina klase ne utiče značajno na performansu modela*, što potvrđuje da je dataset dovoljno balansiran za ovu analizu.



Slika 12: Scatter plot veličine klase vs. F1-Score (Neural Network, All_Features).

6.6 Confusion matrice za sve modele (Expression, All_Features)



Slika 13: Normalizovane matrice konfuzije za svih 5 algoritama. Vidi se da je MLP gotovo savršen, dok kod LR dijagonala bledi – karakteristične greške su između *affirmative/relative* i *topics/relative*.


6.7 Label cilj – binarna klasifikacija aktivna/neaktivna

Za cilj label (0 vs 1), recall za *aktivnu* klasu (manje zastupljena, 35 %) je limitirajući faktor. Vrednosti recall-a za aktivnu klasu po algoritmima (All_Features):

Algoritam	Recall (Aktivna)
Neural Network (MLP)	0,8871
K-Nearest Neighbors	0,8284
Decision Tree	0,8153
Support Vector Machine	0,7642
Logistic Regression	0,6928

Tabela 7: Recall za aktivnu klasu (label=1) po algoritmu.

MLP postiže najbolji recall (**0,89**), Logistic Regression značajno zaostaje (**0,69**) – ne uspeva da prepozna preko 30 % aktivnih frame-ova.



Slika 14: Confusion matrice svih modela za Label cilj (All_Features).

7 Dodatne analize

7.1 GridSearchCV tuning

Za svaki od 5 algoritama urađen je **GridSearchCV** sa 5-fold krosvalidacijom na train setu (cilj Expression, All_Features). Pretraživani prostori parametara i rezultati:

Algoritam	Pretraživano	Test Acc	Najbolji parametri
Logistic Regression	$C \in \{0,01; 0,1; 1; 10\}$, solver: {lbfgs, saga}	0,7926	C=10, lbfgs
KNN	$k \in \{3, 5, 7, 11, 15\}$, weights, metric	0,9694	k=3, manhattan, distance
Decision Tree	max_depth, min_samples_split/leaf, criterion	0,9164	depth=15, entropy
SVM	$C \in \{1, 10\}$, gamma	0,9639	C=10, gamma=auto
MLP	arhitektura, aktivacija, alpha	0,9741	(200,100), tanh, $\alpha=0,0001$

Tabela 8: GridSearchCV rezultati po algoritmu (cilj Expression, All_Features).

Tuning je doneo najveći skok kod **SVM-a** (sa 0,9053 na 0,9639, +5,9 procentnih poena) i **Decision Tree-a** (+2,0 p.p.). Za MLP, default arhitektura iz glavnog eksperimenta je već bila skoro optimalna.

7.2 Stratified k-fold krosvalidacija (5-fold)

Radi provere generalizacije, svaki algoritam je evaluiran i pomoću `StratifiedKFold(n_splits=5)` kroz `Pipeline` (`StandardScaler` → `PCA(75)` → klasifikator), što sprečava data leakage.

Algoritam	Mean Accuracy	Std
MLP (200,100,50), tanh	0,9786	0,0018
KNN (k=5)	0,9407	0,0021
SVM (rbf, C=1)	0,9027	0,0035
Decision Tree (d=15)	0,8242	0,0069
Logistic Regression	0,7451	0,0037

Tabela 9: Cross-validation rezultati (5-fold, PCA_75, Expression).

Standardne devijacije su niske ($\leq 0,007$), što znači da su rezultati *stabilni* kroz različite test splitove. Krosvalidacija potvrđuje rangiranje iz glavne tabele: **MLP** > **KNN** > **SVM** > **DT** > **LR**.

7.3 Čuvanje modela

Za svaki od 5 algoritama sačuvan je **najbolji model** (po accuracy) u `saved_models/`, zajedno sa `StandardScaler`, `PCA`, `SelectKBest` i `LabelEncoder` objektima – dovoljno za kompletnu reproducibilnost na novim podacima.

8 Zaključak

- Najbolji model: **Neural Network (MLP)** sa **PCA(75)** redukcijom za cilj **expression** – **Accuracy** = **98,17 %**, **F1** = 98,17 %.
- Rangiranje algoritama (po prosečnoj accuracy): **MLP** > **KNN** > **SVM** > **DT** > **LR**. Slaba performansa Logističke regresije ($\sim 77\%$) potvrđuje da problem **nije linearno separabilan**.
- `PCA(75)` zadržava 99,78 % varijanse i za MLP daje *bolji* rezultat od svih 300 atributa, dejstvom kao regularizacija. Za jednostavnije modele (LR, DT, SVM), potpun skup atributa je u proseku najbolji.
- `SelectKBest(100)` je u proseku najlošiji jer ANOVA F-test favorizuje pojedinačne feature-e zanemarujući njihove interakcije; za MLP daje $\text{Acc}=0,9594$ (oko 2,2 p.p. ispod PCA varijante od 0,9817).
- Dva ciljna atributa: klasifikacija **9 tipova ekspresija** je iznenađujuće *lakša* (najbolja Acc 98 %) od binarne `label` klasifikacije (najbolja Acc 94 %), jer je binarna agregacija previše heterogena (obuhvata sve aktivne ekspresije pod jednom oznakom), a uz to pati od class imbalance-a 65:35.
- **Veličina klase ne utiče** značajno na performansu (korelacija $-0,09$) – model se ne raspada kod manjih klasa.

- GridSearchCV tuning donosi značajna poboljšanja samo za jednostavnije modele (SVM +5,9 p.p., DT +2,0 p.p.); MLP je već blizu optimalnog sa default konfiguracijom.
- 5-fold krosvalidacija sa niskim standardnim devijacijama ($\leq 0,007$) potvrđuje da rezultati nisu artefakt određenog train/test splita.
- Svi bitni koraci (PCA, `SelectKBest`, KNN k , DT dubina, MLP arhitektura, SVM kernel) potkrepljeni su zasebnim eksperimentima prikazanim figurama u ovom radu.

Svi podaci (original i preprocesiran), figure, `model_results.csv` i svi trenirani modeli se nalaze u repozitorijumu projekta i omogućavaju ponovno izvršavanje celog postupka lokalno.