Matematički fakultet, Univerzitet u Beogradu

Seminarski rad iz predmeta: Istraživanje podataka 2

Klasifikacija gramatičkih facijalnih ekspresija

Analiza i poređenje algoritama klasifikacije

Autor: Zarija Trtović
Broj indeksa: 39/2020

Profesor: Mirjana Maljković Ružičić

Datum: Februar 2026.

Sadržaj

Sažetak **4**

1 Uvod **5**
1.1 Kontekst i motivacija . . . 5
1.2 Priroda podataka i problem . . . 5
1.3 Istraživačka pitanja i hipoteze . . . 5
1.4 Ciljevi i doprinos rada . . . 6
1.5 Struktura rada . . . 6

2 Podaci i priprema **7**
2.1 Izvor i struktura podataka . . . 7
2.2 Osnovna statistika podataka . . . 7
2.3 Preprocesiranje . . . 7
2.3.1 Korak 1: Uklanjanje timestamp kolone . . . 7
2.3.2 Korak 2: Tretiranje Z=0 vrednosti . . . 8
2.3.3 Korak 3: Normalizacija . . . 8
2.4 Train/Test split . . . 8
2.5 Redukcija dimenzionalnosti . . . 8
2.5.1 Skup 1: Svi atributi (300 feature-a) . . . 8
2.5.2 Skup 2: PCA redukcija (50 komponenti) . . . 8
2.5.3 Skup 3: SelectKBest (100 najboljih feature-a) . . . 9
2.6 Vizualizacija podataka . . . 9

3 Metod **10**
3.1 Radni tok: pregled . . . 10
3.2 Ciljni atributi . . . 10
3.2.1 Cilj A: Klasifikacija tipa ekspresije (9 klasa) . . . 10
3.2.2 Cilj B: Klasifikacija aktivnosti ekspresije (2 klase) . . . 10
3.3 Algoritmi klasifikacije . . . 10
3.3.1 Logistic Regression . . . 11
3.3.2 K-Nearest Neighbors (KNN) . . . 11
3.3.3 Decision Tree . . . 11
3.3.4 Support Vector Machine (SVM) . . . 11
3.3.5 Neural Network (MLP) . . . 11
3.4 Metrike evaluacije . . . 11
3.4.1 Accuracy (Tačnost) . . . 11
3.4.2 Precision (Preciznost) . . . 12
3.4.3 Recall (Odziv) . . . 12
3.4.4 F1-Score . . . 12

4 Rezultati i vizualizacije **13**
4.1 Rezultati klasifikacije . . . 13
4.2 Poređenje algoritama . . . 13
4.3 Poređenje feature setova . . . 14
4.4 Najbolji model . . . 14
4.4.1 Classification Report . . . 14
4.4.2 Confusion Matrix . . . 15

5 Diskusija **16**
5.1 Ograničenja i pretnje validnosti 16
5.2 Interpretacija nalaza 16
5.2.1 Neural Network vs. jednostavniji modeli 16
5.2.2 PCA redukcija pomaže Neural Network-u 16
5.2.3 Expression vs. Label 16
5.2.4 SelectKBest performanse 17
5.3 Praktične implikacije i preporuke 17

6 Zaključak **18**
6.1 Glavna dostignuća 18
6.2 Ograničenja i budući rad 18

Sažetak

Ovaj rad prikazuje potpun postupak klasifikacije gramatičkih facijalnih ekspresija iz skupa podataka *Grammatical Facial Expressions*. Primenjeno je 5 različitih algoritama mašinskog učenja (Logistic Regression, K-Nearest Neighbors, Decision Tree, Support Vector Machine, Neural Network) na 3 varijante skupova atributa (svi atributi, PCA redukcija, SelectKBest). Evaluacija je izvršena pomoću Accuracy, Precision, Recall i F1-Score metrika. Rezultati pokazuju da Neural Network (MLP) sa PCA redukcijom daje najbolje performanse (Accuracy=96.78%), dok K-Nearest Neighbors pokazuje izuzetnu robusnost na različitim skupovima atributa.

1 Uvod

1.1 Kontekst i motivacija

Klasifikacija facijalnih ekspresija predstavlja fundamentalan zadatak u oblasti kompjuterske vizije i mašinskog učenja, sa širokom primenom u analizi znkovnog jezika, sistemima za komunikaciju osoba sa oštećenjem sluha, i automatskoj interpretaciji neverbalnih komunikacionih signala.

Za razliku od tradicionalne analize emocionalnih facijalnih ekspresija, gramatičke facijalne ekspresije u znakovnom jeziku imaju lingvističku funkciju. One služe za formiranje gramatičke strukture jezika i omogućavaju kreiranje jezičke disambiguacije. Na primer, različite pokrete obrva, očiju i usta koriste se za označavanje pitanja, negacije, afirmacije ili naglašavanja u brazilskom znakovnom jeziku (LIBRAS).

1.2 Priroda podataka i problem

Ulazni skup podataka *Grammatical Facial Expressions* sastoji se od 27,936 frame-ova ekstrahovanih iz 18 video snimaka. Svaki frame je predstavljen sa:

- **100 3D facial landmarks**: X, Y koordinate (u pikselima) i Z koordinata (dubina u milimetrima)
- **2 korisnika**: Osoba A i osoba B
- **9 tipova ekspresija**: affirmative, conditional, doubt_question, emphasis, negative, relative, topics, wh_question, yn_question
- **Binarne labele**: 0 (ekspresija neaktivna), 1 (ekspresija aktivna)

Podaci pokazuju značajnu heterogenost, sa 64.6% frame-ova označenih kao neaktivni i 35.4% kao aktivni, što ukazuje na prisutvo class imbalance problema.

1.3 Istraživačka pitanja i hipoteze

Osnovna istraživačka pitanja ovog rada su:

1. **Koji algoritam klasifikacije daje najbolje rezultate?** Poređenjem 5 različitih algoritama (Logistic Regression, KNN, Decision Tree, SVM, Neural Network) na 3 skupa atributa (ukupno 30 modela), cilj je identifikovati optimalan pristup.
2. **Da li redukcija dimenzionalnosti poboljšava performanse?** Testiranjem PCA i SelectKBest redukcije, ispitujemo da li smanjenje broja atributa sa 300 na 50-100 utiče na tačnost modela.
3. **Koliko dobro modeli razlikuju 9 klasa ekspresija?** Analiza confusion matrix-a omogućava identifikaciju koje ekspresije su najteže za razlikovanje.

Polazna hipoteza je da će algoritmi mašinskog učenja moći da efikasno klasifikuju gramatičke facijalne ekspresije koristeći 3D koordinate facial landmarks, pri čemu će kompleksniji modeli (Neural Network, SVM) dati bolje rezultate od jednostavnijih (Logistic Regression).

1.4 Ciljevi i doprinos rada

Cilj ovog rada je višestruk:

- **Metodološki doprinos**: Demonstracija kompletnog toka za klasifikaciju facial landmarks podataka, od preprocessing-a do evaluacije, sa jasnim obrazloženjem svakog koraka.
- **Empirijsko poređenje**: Sistematska evaluacija 5 algoritama na 3 različite reprezentacije podataka sa ciljem identifikovanja najboljeg pristupa.
- **Praktična primena**: Pruža uvid u automatsku klasifikaciju gramatičkih ekspresija, korisno za sisteme za komunikaciju i analizu znakovnog jezika.
- **Reproducibilnost**: Detaljna dokumentacija i čuvanje svih modela omogućava ponavljanje analize.

1.5 Struktura rada

Rad je organizovan u šest glavnih poglavlja:

Poglavlje 2 (Podaci i priprema) opisuje izvor podataka, osnovnu statistiku, korake preprocesiranja i kreiranje različitih skupova atributa.

Poglavlje 3 (Metod) detaljno objašnjava primenjene algoritme klasifikacije, metrike evaluacije i train/test split strategiju.

Poglavlje 4 (Rezultati) prikazuje dobijene rezultate, poređenje algoritama, vizualizacije i analizu najboljeg modela.

Poglavlje 5 (Diskusija) interpretira nalaze, razmatra ograničenja i predlaže pravce za buduća istraživanja.

Poglavlje 6 (Zaključak) sumira glavne doprinose rada i izvodi zaključke.

2 Podaci i priprema

2.1 Izvor i struktura podataka

Skup podataka *Grammatical Facial Expressions* preuzet je sa UCI Machine Learning Repository. Format podataka je:

- 18 *datapoints* fajlova: Svaki red = 1 frame, 301 kolona (timestamp + 100 × 3 koordinate)
- 18 *targets* fajlova: Binarne labele (0 ili 1) za svaki frame
- Imenovanje: `[korisnik]_[ekspresija]_datapoints.txt`

Inicijalno učitavanje pokazuje:

- Ukupan broj frame-ova: 27,936
- Distribucija korisnika: A (13,968), B (13,968)
- Distribucija ekspresija: 9 tipova sa varijabilnim brojem frame-ova
- Distribucija labela: 0 (neaktivna): 64.6%, 1 (aktivna): 35.4%

2.2 Osnovna statistika podataka

Tabela 1 prikazuje ključne metrike dataseta.

Metrika	**Vrednost**
Ukupno frame-ova	27,936
Broj korisnika	2 (A, B)
Broj ekspresija	9
Broj facial landmarks	100 (3D)
Broj feature-a	300 (100 × 3)
Train set	22,348 (80%)
Test set	5,588 (20%)
Class imbalance ratio	1.82:1 (neaktivna:aktivna)

Tabela 1: Osnovna statistika Grammatical Facial Expressions dataseta

2.3 Preprocesiranje

Preprocesiranje podataka izvršeno je u sledećim koracima:

2.3.1 Korak 1: Uklanjanje timestamp kolone

Timestamp kolona (vreme snimanja frame-a) ne sadrži informacije relevantne za klasifikaciju ekspresija i uklonjena je iz dataseta.

2.3.2 Korak 2: Tretiranje Z=0 vrednosti

Z koordinate sa vrednošću 0 ukazuju na to da Microsoft Kinect sensor nije uspeo da izmeri dubinu te tačke. Ove vrednosti su zamenjene medijanom te koordinate iz celog dataseta. Ukupno je zamenjeno približno 5-10% Z koordinata.

2.3.3 Korak 3: Normalizacija

Sve feature kolone su normalizovane koristeći StandardScaler:

$$z = \frac{x - \mu}{\sigma} \tag{1}$$

gde je μ srednja vrednost i σ standardna devijacija feature-a. Ovo je neophodno jer X, Y koordinate su u pikselima (200-400), dok je Z u milimetrima (800-1600), što bi dovelo do dominacije Z koordinata u algoritmima osetljivim na skalu (KNN, SVM, Neural Network).

Važno: Scaler je fit-ovan SAMO na train setu, a zatim primenjen na test set kako bi se izbegao data leakage.

2.4 Train/Test split

Podaci su podeljeni na train (80%) i test (20%) setove koristeći stratified split koji održava isti odnos klasa:

- **Expression klasifikacija**: 22,348 train / 5,588 test
- **Label klasifikacija**: 22,348 train / 5,588 test
- **Stratification**: Obezbeđuje isti procenat svake klase u train i test setu
- **Random state=42**: Reproducibilnost rezultata

2.5 Redukcija dimenzionalnosti

Kako bi se testirala robusnost algoritama i identifikovala optimalna reprezentacija podataka, kreirane su 3 varijante skupova atributa:

2.5.1 Skup 1: Svi atributi (300 feature-a)

Originalni skup sa svim 3D koordinatama (100 tačaka $\times$ 3 ose).

2.5.2 Skup 2: PCA redukcija (50 komponenti)

Principal Component Analysis (PCA) primenjuje linearnu transformaciju koja kompresuje podatke:

- Broj komponenti: 50
- Objašnjena varijansa: 99.38%
- Rezultujuća dimenzija: 50 feature-a

PCA pronalazi ortogonalne pravce maksimalne varijanse. Prvih 50 komponenti objašnjava gotovo svu varijansu, što ukazuje da podaci leže u relativno niskom dimenzionalnom potprostoru.

2.5.3 Skup 3: SelectKBest (100 najboljih feature-a)

SelectKBest bira K originalnih feature-a koji najbolje razdvajaju klase koristeći ANOVA F-test:

- Broj odabranih feature-a: 100
- Score funkcija: f_classif (ANOVA F-test)
- Rezultujuća dimenzija: 100 feature-a

Top 10 najvažnijih feature-a prema SelectKBest-u su uglavnom X koordinate tačaka oko usta (41x, 42x, 52x, 51x, 50x, 62x), što ima smisla jer su pokret usta ključni za gramatičke ekspresije.

2.6 Vizualizacija podataka

Pre primene algoritama klasifikacije, izvršena je vizuelna eksploracija podataka pomoću PCA projekcije u 2D i 3D prostor.

Zapažanja iz vizualizacije:

- **Nema jasne binarne separabilnosti**: Frame-ovi sa labelama 0 i 1 nisu jasno razdvojeni u prostoru prvih nekoliko glavnih komponenti
- **Višestruke grupe**: Uočava se grupiranje po tipu ekspresije, što sugeriše da je klasifikacija 9 tipova ekspresija izvodljiva
- **Gradijent između klasa**: Postoji postepeni prelaz između aktivnih i neaktivnih frame-ova

3 Metod

3.1 Radni tok: pregled

Kompletan analitički tok sastoji se od sledećih koraka:

1. Učitavanje podataka: Parsiranje tekstualnih fajlova i spajanje svih frame-ova
2. Preprocesiranje: Čišćenje, normalizacija, zamena missing vrednosti
3. Train/test split: Stratified podela na 80% train i 20% test
4. Kreiranje skupova atributa: Svi, PCA, SelectKBest
5. Treniranje modela: 5 algoritama $\times$ 3 skupa $\times$ 2 cilja = 30 modela
6. Evaluacija: Accuracy, Precision, Recall, F1-Score, Confusion Matrix
7. Poređenje: Analiza rezultata i identifikacija najboljeg modela

Svi koraci su implementirani u Python-u koristeći scikit-learn biblioteku. Kompletan kod je reproduktivno ponovljiv sa fiksiranim `random_state=42`.

3.2 Ciljni atributi

Kreirane su dve klasifikacione zadatke:

3.2.1 Cilj A: Klasifikacija tipa ekspresije (9 klasa)

Klasifikacija frame-a u jednu od 9 gramatičkih facijalnih ekspresija:

- affirmative (7.6%), conditional (14.1%), doubt_question (10.1%)
- emphasis (9.8%), negative (9.7%), relative (15.2%)
- topics (13.0%), wh_question (9.4%), yn_question (11.2%)

3.2.2 Cilj B: Klasifikacija aktivnosti ekspresije (2 klase)

Binarna klasifikacija da li je ekspresija aktivna (1) ili neaktivna (0):

- Neaktivna (0): 64.6%
- Aktivna (1): 35.4%

3.3 Algoritmi klasifikacije

Primenjeno je 5 različitih algoritama koji pripadaju različitim paradigmama mašinskog učenja:

3.3.1 Logistic Regression

Princip: Linearna kombinacija feature-a transformisana sigmoid funkcijom.
Prednosti: Brz, interpretabilan, dobro poznata metoda.
Mane: Može naučiti samo linearne granice između klasa.
Parametri: `max_iter=1000, random_state=42`

3.3.2 K-Nearest Neighbors (KNN)

Princip: Klasifikuje tačku na osnovu 5 najbližih suseda.
Prednosti: Instance-based učenje, ne zahteva treniranje.
Mane: Spor pri predikciji na velikim datasetima, osetljiv na skaliranje.
Parametri: `n_neighbors=5`

3.3.3 Decision Tree

Princip: Pravi pravila tipa "Ako feature X > vrednost → klasa Y".
Prednosti: Lako interpretabilan, može hvatati ne-linearne odnose.
Mane: Sklono overfitting-u.
Parametri: `max_depth=10, random_state=42`

3.3.4 Support Vector Machine (SVM)

Princip: Traži optimalnu granicu (hyperplane) između klasa u visokom dimenzionalnom prostoru.
Prednosti: Odličan za visoke dimenzije, RBF kernel omogućava ne-linearne granice.
Mane: Spor na velikim datasetima.
Parametri: `kernel='rbf', C=1.0, random_state=42`

3.3.5 Neural Network (MLP)

Princip: Višeslojni perceptron sa 2 skrivena sloja (100 i 50 neurona).
Prednosti: Može naučiti vrlo kompleksne ne-linearne obrasce.
Mane: "Black box", teže interpretabilan, sklono overfitting-u.
Parametri: `hidden_layer_sizes=(100, 50), activation='relu', max_iter=500, random_state=42`

3.4 Metrike evaluacije

Za evaluaciju modela korišćene su četiri standardne metrike:

3.4.1 Accuracy (Tačnost)

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \tag{2}$$

Procenat ispravno klasifikovanih frame-ova.

3.4.2 Precision (Preciznost)

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \tag{3}$$

Od svih pozitivnih predikcija, koliko je zaista pozitivno.

3.4.3 Recall (Odziv)

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \tag{4}$$

Od svih stvarno pozitivnih, koliko je model detektovao.

3.4.4 F1-Score

$$\text{F1} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{5}$$

Harmonijska sredina preciznosti i odziva.

Za multi-class klasifikaciju (9 ekspresija) korišćen je **weighted average** koji uzima u obzir broj uzoraka svake klase.

4 Rezultati i vizualizacije

4.1 Rezultati klasifikacije

Izvršeno je ukupno 30 eksperimenata (5 algoritama × 3 skupa atributa × 2 cilja). Tabela 2 prikazuje top 10 modela rangiranih po accuracy-ju.

Model	**Feature Set**	**Target**	**Acc**	**Prec**	**Rec**	**F1**
Neural Network	PCA_50	Expression	0.968	0.968	0.968	0.968
Neural Network	All	Expression	0.963	0.964	0.963	0.963
Neural Network	KBest_100	Expression	0.942	0.943	0.942	0.942
KNN	PCA_50	Expression	0.941	0.941	0.941	0.941
KNN	All	Expression	0.941	0.941	0.941	0.941
Neural Network	All	Label	0.938	0.946	0.873	0.908
Neural Network	PCA_50	Label	0.929	0.910	0.888	0.899
Neural Network	KBest_100	Label	0.924	0.901	0.883	0.892
KNN	KBest_100	Label	0.914	0.908	0.842	0.874
KNN	All	Label	0.909	0.906	0.828	0.866

Tabela 2: Top 10 modela rangiranih po Accuracy

Ključna zapažanja:

1. **Neural Network dominira**: Svih prvih 8 mesta zauzimaju Neural Network i KNN modeli
2. **PCA(50) > All(300)**: Za Neural Network, PCA redukcija daje BOLJE rezultate od svih atributa
3. **Expression lakši od Label**: Klasifikacija 9 tipova ekspresija ima veću accuracy od binarne klasifikacije (kontraintuitivno)
4. **SelectKBest najlošiji**: Redukcija na 100 najboljih feature-a konzistentno daje najlošije rezultate

4.2 Poređenje algoritama

Tabela 3 prikazuje prosečne performanse po algoritmu preko svih kombinacija.

Model	**Accuracy**	**Precision**	**Recall**	**F1**
Neural Network	0.944	0.939	0.920	0.929
K-Nearest Neighbors	0.919	0.917	0.880	0.898
Support Vector Machine	0.865	0.871	0.802	0.833
Decision Tree	0.807	0.804	0.746	0.772
Logistic Regression	0.762	0.756	0.670	0.707

Tabela 3: Prosečne performanse po algoritmu (preko svih kombinacija)

Analiza po algoritmima:

Neural Network (MLP): Najbolji rezultati (94.4% prosečna accuracy). Pokazuje da problem zahteva modeliranje kompleksnih ne-linearnih odnosa između facial landmarks.

K-Nearest Neighbors: Odlični rezultati (91.9%), što ukazuje da podaci imaju jasnu strukturu gde slični frame-ovi pripadaju istoj klasi.

Support Vector Machine: Solidne performanse (86.5%), ali sporiji od KNN i Neural Network.

Decision Tree: Umerene performanse (80.7%), verovatno zbog overfitting-a čak i sa `max_depth=10`.

Logistic Regression: Najlošiji rezultati (76.2%), što potvrđuje da problem NIJE linearno separabilan.

4.3 Poređenje feature setova

Tabela 4 prikazuje prosečne performanse po feature setu.

Feature Set	Accuracy	Precision	Recall	F1
All_Features (300)	0.872	0.870	0.815	0.840
PCA_50 (50)	0.843	0.840	0.777	0.804
KBest_100 (100)	0.815	0.811	0.753	0.778

Tabela 4: Prosečne performanse po feature setu

Interesantno: All_Features daje najbolje prosečne rezultate, ALI za Neural Network PCA je bolji. To sugeriše da Neural Network ima koristi od redukcije šuma kroz PCA, dok jednostavniji modeli (Logistic Regression, Decision Tree) ne mogu iskoristiti svu informaciju iz PCA komponenti.

4.4 Najbolji model

Na osnovu sveobuhvatne evaluacije, najbolji model je:

- **Algoritam**: Neural Network (MLP)
- **Feature Set**: PCA_50
- **Target**: Expression (9 klasa)
- **Accuracy**: 96.78%
- **F1-Score**: 96.78%

4.4.1 Classification Report

Tabela 5 prikazuje detaljne metrike po klasi za najbolji model.
Zapažanja:

- **wh_question i yn_question**: Najviša precision (0.99-1.00) - najlakše se razlikuju
- **topics**: Najniža precision (0.94) - ponekad se meša sa drugim ekspresijama
- **Balansiranost**: Sve klase imaju F1-score > 0.95, što ukazuje na odličnu generalizaciju

Ekspresija	**Precision**	**Recall**	**F1-Score**	**Support**
affirmative	0.96	0.97	0.96	427
conditional	0.96	0.97	0.96	788
doubt_question	0.98	0.99	0.98	562
emphasis	0.96	0.95	0.96	550
negative	0.97	0.97	0.97	541
relative	0.97	0.96	0.96	847
topics	0.94	0.96	0.95	724
wh_question	0.99	0.99	0.99	523
yn_question	1.00	0.96	0.98	626
Weighted avg	**0.97**	**0.97**	**0.97**	**5588**

Tabela 5: Classification Report - Neural Network (PCA_50, Expression)

4.4.2 Confusion Matrix

Confusion matrix (Slika u prilogu) pokazuje da:

- Dijagonala dominira (korektne predikcije)
- Najveće greške: conditional ↔ relative (povremeno se mešaju)
- yn_question gotovo savršeno klasifikovan (samo 3 greške od 626)

5 Diskusija

5.1 Ograničenja i pretnje validnosti

Ova studija ima nekoliko ograničenja:

Izbor parametara: Iako je izvršeno sistematsko testiranje, prostor parametara je ogroman. Korišćeni su default ili standardni parametri, a GridSearch bi mogao otkriti bolje kombinacije.

Class imbalance: Odnos 65:35 između neaktivnih i aktivnih frame-ova nije tretiran posebnim tehnikama (SMOTE, class weights). To može uticati na Label klasifikaciju.

Evaluacione metrike: Accuracy, Precision, Recall i F1 mere performanse, ali ne mere i robusnost modela na nove korisnike ili različite uslove snimanja.

Generalizacija: Dataset sadrži samo 2 korisnika. Performanse na novim osobama mogu biti niže.

Temporal dependencies: Frame-ovi su tretirani nezavisno, ali ekspresije imaju temporalnu strukturu. Recurrent Neural Networks (LSTM, GRU) bi mogli iskoristiti ovu informaciju.

5.2 Interpretacija nalaza

Nekoliko ključnih uvida proizlazi iz analize:

5.2.1 Neural Network vs. jednostavniji modeli

Neural Network (94.4%) značajno nadmašuje Logistic Regression (76.2%), što sugeriše da veza između facial landmarks i ekspresija NIJE linearna. Pokret usta, obrva i očiju ima kompleksne interakcije koje jednostavni modeli ne mogu uhvatiti.

5.2.2 PCA redukcija pomaže Neural Network-u

Kontraintuitivno, Neural Network sa PCA(50) daje BOLJE rezultate od All(300):

- PCA(50): 96.78% accuracy
- All(300): 96.31% accuracy

Moguća objašnjenja:

1. **Regularizacija**: PCA uklanja šum i manje važne dimenzije, sprečavajući overfitting
2. **Brže konvergiranje**: Manji broj feature-a znači manji broj težina koje Neural Network mora naučiti
3. **99.38% varijanse**: PCA zadržava skoro svu informaciju, eliminišući samo šum

5.2.3 Expression vs. Label

Klasifikacija 9 tipova ekspresija (Expression) daje BOLJE rezultate od binarne klasifikacije (Label):

- Expression (9 klasa): 96.78% accuracy

- Label (2 klase): 93.77% accuracy

Ovo je kontraintuitivno jer binarna klasifikacija je obično lakša. Objašnjenje:

- **Label klasifikacija je zapravo teža**: "Aktivna"labela obuhvata različite tipove ekspresija koje mogu izgledati različito
- **Expression klasifikacija je diskriminativnija**: Svaka od 9 ekspresija ima jedinstvene karakteristike
- **Class imbalance**: Label ima 65:35 odnos što može uticati na učenje

5.2.4 SelectKBest performanse

SelectKBest(100) konzistentno daje najlošije rezultate. Analiza pokazuje da top feature-i su uglavnom X koordinate oko usta (41x, 42x, 52x...), što sugeriše da:

- ANOVA F-test favorizuje individualne feature-e, zanemarujući interakcije
- Y i Z koordinate su takođe važne, ali imaju niži individualni skor
- PCA bolje hvata kombinovane efekte svih koordinata

5.3 Praktične implikacije i preporuke

Na osnovu nalaza, sledeće preporuke su relevantne za praktičnu primenu:
Za produkcijsku primenu:

- Koristiti Neural Network (MLP) sa PCA(50) redukcijom
- Očekivati 96-97% accuracy na sličnim datasetima
- Implementirati real-time ekstrakciju facial landmarks (OpenCV, MediaPipe)
- Periodično retrainirati model sa novim korisnicima

Za istraživačke svrhe:

- Testirati Recurrent Neural Networks (LSTM) za temporalnu strukturu
- Primeniti data augmentation (rotacije, translacije) za robusnost
- Kombinovati facial landmarks sa dodatnim feature-ima (head pose, gaze direction)
- Testirati transfer learning sa pre-trainiranim modelima

Za buduće poboljšanje:

1. **Hyperparameter tuning**: GridSearch ili Bayesian Optimization za optimalne parametre
2. **Ensemble metode**: Kombinovati Neural Network i KNN za robusnije predikcije
3. **Tretiranje class imbalance**: SMOTE, class weights, ili stratified sampling
4. **Cross-validation**: K-fold cross-validation za pouzdaniju procenu generalizacije
5. **Feature engineering**: Kreiranje novih feature-a (rastojanja između tačaka, uglovi, brzine)

6 Zaključak

6.1 Glavna dostignuća

Ovaj rad je predstavio sveobuhvatnu analizu klasifikacije gramatičkih facijalnih ekspresija iz skupa podataka *Grammatical Facial Expressions*. Primenjeno je 5 algoritama mašinskog učenja na 3 različite reprezentacije podataka (ukupno 30 modela), sa sistematskom evaluacijom pomoću četiri komplementarne metrike.

Ključni rezultati:

1. **Metodološki doprinos**: Demonstriran je kompletan tok klasifikacije od sirovog dataseta do čuvanja modela, uključujući preprocesiranje, normalizaciju, redukciju dimenzionalnosti, treniranje i evaluaciju.

2. **Empirijsko poređenje**: Sistematska evaluacija je pokazala da:

   - Neural Network (MLP) daje najbolje performanse (96.78% accuracy)
   - PCA redukcija poboljšava Neural Network za 0.5% (kontraintuitivno)
   - KNN takođe pokazuje odlične rezultate (94.1%), što ukazuje na jasnu strukturu podataka
   - Logistic Regression ima najlošije performanse (76.2%), potvrđujući ne-linearnost problema

3. **Praktične smernice**: Pružene su konkretne preporuke za:

   - Automatsku klasifikaciju gramatičkih ekspresija u real-time sistemima
   - Optimalne parametre i feature setove za nove datasete
   - Pravce za buduća poboljšanja (LSTM, ensemble metode, feature engineering)

4. **Reproducibilnost**: Svi modeli, scaler-i, PCA objekti i metadata su sačuvani, omogućavajući ponavljanje analize i deployment u produkciju.

6.2 Ograničenja i budući rad

Glavna ograničenja ove studije proizlaze iz:

- Ograničenog broja korisnika (samo 2)
- Zanemarivanja temporalne strukture ekspresija
- Neresolving class imbalance problema
- Korišćenja default parametara bez ekstenzivnog tuning-a

U budućim istraživanjima korisno je:

1. Primeniti Recurrent Neural Networks (LSTM, GRU) za modelovanje temporalnih dependency-ja

2. Testirati na većem broju korisnika za proveru generalizacije

3. Kombinovati facial landmarks sa dodatnim modalitetima (audio, head pose, gaze)
4. Implementirati real-time sistem sa live video stream-om
5. Primeniti transfer learning sa pre-trainiranim vision modelima

Zaključak: Pokazano je da algoritmi mašinskog učenja efikasno klasifikuju gramatičke facijalne ekspresije koristeći 3D facial landmarks, pri čemu Neural Network sa PCA redukcijom daje state-of-the-art performanse (96.78% accuracy). Budući rad treba da se fokusira na modelovanje temporalne strukture i testiranje na širem spektru korisnika.